



(4) Fundamentos de inferencia estadística

David Fernández Amorós david@issi.uned.es
Universidad Nacional de Educación a Distancia

**Plasencia 2026 – Curso de Análisis y Visualización de Datos: Estadística
Práctica con R e Inteligencia Artificial**

Objetivos de la inferencia estadística

La **inferencia estadística** intenta conocer acerca de las *poblaciones* a partir de lo encontrado en las *muestras*:

- ¿Es el hallazgo encontrado en la muestra analizada una verdad general válida para toda la población?
- ¿Qué resultados son mera anécdota particular de la muestra y cuáles son válidos más allá de ella?

Objetivos de la inferencia estadística

La **inferencia estadística** intenta conocer acerca de las *poblaciones* a partir de lo encontrado en las *muestras*:

- ¿Es el hallazgo encontrado en la muestra analizada una verdad general válida para toda la población?
- ¿Qué resultados son mera anécdota particular de la muestra y cuáles son válidos más allá de ella?

El 98 % de los profesionales con estudios superiores no entienden los fundamentos de la inferencia estadística^a (qué es el p -valor, intervalo de confianza, estadísticamente significativo, etc.)

^aPrieto, I. Herranz. *¿Qué significa estadísticamente significativo? La falacia del criterio del 5 % en la investigación científica*. Ed. Díaz de Santos, 2005.

Procedimiento de la inferencia estadística

Tenemos una **hipótesis** que testear, que llamaremos H_a (este medicamento cura el cancer) y la hipótesis nula, H_0 , que es la negación de esta. Los datos van a determinar cual es la correcta:

- Obtenemos unos datos experimentales, D y calculamos $\Pr(D \mid H_0)$. Esta cantidad se denomina p -valor.
- Si p es pequeño, digamos menor que 0.05 o 0.01, rechazamos la hipótesis nula.

Procedimiento de la inferencia estadística

Aquí podemos realizar dos tipos de errores:

- El error de tipo I: Rechazar la hipótesis nula cuando es cierta.
- El error de tipo II: Aceptar la hipótesis nula, cuando es falsa.

El azar es traicionero

- Quiero comprobar si el fenómeno X causa Y .
- Hago un muestreo y miro si están relacionadas.

<http://www.tylervigen.com/spurious-correlations>

Modus Ponens

$$A \Rightarrow B, A \vdash B$$

- Todo hombre es filósofo.
- Sócrates es un hombre.
- Por tanto, Sócrates es filósofo.

Modus Tollens (negación del consecuente o ley de contraposición)

$$A \Rightarrow B, \neg B \vdash \neg A$$

- Si una persona es un marciano, no es miembro del congreso.
- Esta persona es miembro del congreso.
- Por tanto, no es un marciano.

Modus Tollens (negación del consecuente o ley de contraposición)

He aquí un razonamiento correcto, pero como la premisa es falsa, la conclusión también lo es.

- Si una persona es estadounidense, no es miembro del congreso. ****FALSO****
- Esta persona es miembro del congreso.
- Por tanto, no es estadounidense.

Ejemplo probabilístico

Podemos arreglar la premisa haciéndola probabilística, en vez de absoluta.

- Si una persona es estadounidense, probablemente no es miembro del congreso. ****CIERTO****
- Esta persona es miembro del congreso.
- Por tanto, probablemente no es estadounidense.

Digamos que:

- $H_0 \equiv$ esta persona es estadounidense.
- $D \equiv$ esta persona es miembro del congreso.

Es exactamente lo mismo que decir que si H_0 es cierta, probablemente no ocurriría D . Pero D ha ocurrido, por lo que H_0 es probablemente falsa.

Ejemplo probabilístico

- Hay que ejercer un poco el sentido común al hacer un contraste de hipótesis.
- Este método de contraste es malísimo. Está mal diseñado. Eso no tiene arreglo.

La falacia de la tasa base

La cantidad interesante no es $\Pr(D \mid H_0)$, sino $\Pr(H_0 \mid D)$, pero esa en general no la podemos calcular. Aunque a veces sí:

La incidencia de la esquizofrenia en adultos es del 2 %. Se propone un procedimiento de prueba que tiene al menos un 95 % de sensibilidad y un 97 % de especificidad. En terminos técnicos: $\Pr(\text{normal} \mid H_0) \approx 0,97$, $\Pr(\text{esquizofrenia} \mid H_1) \geq 0,95$. Sea:

- $H_0 \equiv$ el sujeto es normal
- $H_1 \equiv$ el sujeto es esquizofrénico
- $D \equiv$ El resultado del test es esquizofrenia

La falacia de la tasa base

- Si el test sale esquizofrenia, $\Pr(D \mid H_0)$ es menos de 0.03, por lo que rechazamos H_0 con un p -valor *estadísticamente significativo* y declaramos loco al sujeto.
- Pero esa no es la probabilidad ($H_0 \mid D$), e.d., la probabilidad de que es sujeto sea normal aunque el test haya salido positivo. De hecho, usando el teorema de Bayes, se calcula que ese valor es 0.607.

La falacia de la tasa base

Esto se ve más claro con la tabla completa:

Resultado	Normal	Esquizofrénico	Total
Test negativo	949	1	950
Test positivo	30	20	50
Total	979	21	1 000

La falacia de la tasa base

Esto se ve más claro con la tabla completa:

Resultado	Normal	Esquizofrénico	Total
Test negativo	949	1	950
Test positivo	30	20	50
Total	979	21	1 000

- ¡De los 50 casos positivos para esquizofrenia, 30 eran normales!
- Como la tasa base de esquizofrenia es tan baja, el p -valor no nos dice gran cosa sobre la probabilidad *a posteriori* de H_0 .
- A priori, $\Pr(H_0) = 0,998$, a posteriori, $\Pr(H_0 \mid D) = 0,607$.

Ejemplo de inf. estadística

Se sabe que cierta enfermedad se cura espontáneamente en el 5 % de los casos. Para averiguar si la medicina M aumenta las curaciones, se prueba en una muestra con 9 enfermos y se consigue curación en 3 de ellos.

- Vamos a suponer que M no aumenta las curaciones $\rightsquigarrow$
Hipótesis Nula H_0
- Suponiendo que H_0 se cumple, ¿que probabilidad tenemos de encontrarnos con una muestra como la del enunciado? $\rightsquigarrow$
 p -valor
- Si la probabilidad es extremadamente pequeña, el resultado invita a rechazar la suposición de partida.
- Antiguamente, había que utilizar tablas para determinar si la probabilidad era menor del umbral fijado, como el 0.05 o 0.01.

Ejemplo de inf. estadística

Se sabe que cierta enfermedad se cura espontáneamente en el 5 % de los casos. Para averiguar si la medicina M aumenta las curaciones, se prueba en una muestra con 9 enfermos y se consigue curación en 3 de ellos.

- Vamos a suponer que M no aumenta las curaciones
 H_0 = el medicamento M es inútil, es decir, cura al 5 %

Ejemplo de inf. estadística

Se sabe que cierta enfermedad se cura espontáneamente en el 5 % de los casos. Para averiguar si la medicina M aumenta las curaciones, se prueba en una muestra con 9 enfermos y se consigue curación en 3 de ellos.

- Vamos a suponer que M no aumenta las curaciones
 H_0 = el medicamento M es inútil, es decir, cura al 5 %
 H_a = el medicamento M es útil

Ejemplo de inf. estadística

Se sabe que cierta enfermedad se cura espontáneamente en el 5 % de los casos. Para averiguar si la medicina M aumenta las curaciones, se prueba en una muestra con 9 enfermos y se consigue curación en 3 de ellos.

- Vamos a suponer que M no aumenta las curaciones
 H_0 = el medicamento M es inútil, es decir, cura al 5 %
 H_a = el medicamento M es útil
- Suponiendo H_0 , ¿que probabilidad tenemos de encontrarnos con una muestra como la del enunciado?
 $Pr(3 \text{ o más curaciones en } 9 \text{ enfermos} | H_0) =$
 $pbinom(2, 9, 0.05, FALSE) = 0.00836104$

Ejemplo de inf. estadística

Se sabe que cierta enfermedad se cura espontáneamente en el 5 % de los casos. Para averiguar si la medicina M aumenta las curaciones, se prueba en una muestra con 9 enfermos y se consigue curación en 3 de ellos.

- Vamos a suponer que M no aumenta las curaciones
 H_0 = el medicamento M es inútil, es decir, cura al 5 %
 H_a = el medicamento M es útil
- Suponiendo H_0 , ¿que probabilidad tenemos de encontrarnos con una muestra como la del enunciado?
 $Pr(3 \text{ o más curaciones en } 9 \text{ enfermos} | H_0) =$
 $\text{pbinom}(2, 9, 0.05, \text{FALSE}) = 0.00836104$
- Como el $p\text{-valor} = 0.00836104$, rechazamos H_0

Ejemplo de inf. estadística

Se sabe que cierta enfermedad se cura espontáneamente en el 5 % de los casos. Para averiguar si la medicina M aumenta las curaciones, se prueba en una muestra con 9 enfermos y se consigue curación en 3 de ellos.

Si queremos ir poco a poco en R ...

```
1 pacientes <- 9
2 rep <- 10000
3 matriz <- matrix(sample(c("E", "C"),
4                       size = pacientes * rep,
5                       replace = TRUE, prob = c(0.95, 0.05)),
6                 nrow = rep, ncol = pacientes)
7 conteoC <- rowSums(matriz == "C")
8 sum(conteoC >= 3) / rep
9 [1] 0.0088
```

Error de concepto sobre el p -valor

- Mucha gente piensa que el p -valor es la probabilidad de que H_0 sea cierta teniendo en cuenta la muestra

$$Pr(H_0|\text{muestra})$$

Error de concepto sobre el p -valor

- Mucha gente piensa que el p -valor es la probabilidad de que H_0 sea cierta teniendo en cuenta la muestra

$$Pr(H_0|\text{muestra})$$

- Sin embargo, el p -valor es la probabilidad de que se produzca la muestra suponiendo que H_0 sea cierta

$$Pr(\text{muestra}|H_0)$$

Error de concepto sobre el p -valor

- Mucha gente piensa que el p -valor es la probabilidad de que H_0 sea cierta teniendo en cuenta la muestra

$$Pr(H_0|\text{muestra})$$

- Sin embargo, el p -valor es la probabilidad de que se produzca la muestra suponiendo que H_0 sea cierta

$$Pr(\text{muestra}|H_0)$$

- En general, $Pr(H_0|\text{muestra}) \neq Pr(\text{muestra}|H_0)$

$$Pr(\text{ha llovido}|\text{suelo mojado}) \neq Pr(\text{suelo mojado}|\text{ha llovido})$$

¿Qué hacer? ¿Aceptar H_0 o rechazarla?

- Dado un grupo de observaciones, la teoría de los contrastes de hipótesis nos dice que no hay más opciones: O bien decimos que los datos son compatibles con la hipótesis nula o bien la rechazamos.
- Pero hay otras opciones. Siempre hay más opciones:

Recuerde que «El propósito central de un experimento no es precipitar la toma de decisiones, sino propiciar un reajuste en el grado de confianza que uno tiene en la veracidad de cierta hipótesis. . . la tarea del científico no es prescribir acciones sino establecer convicciones razonables. » L. C. Silva.

Simulación en R



Simulación en R

R ofrece cantidad de funciones de distribución de probabilidad y generación aleatoria de muestras:

- Dist. Normal: `dnorm`, `pnorm`, `qnorm`, `rnorm`
- Dist. Binomial: `dbinom`, `pbinom`, `qbinom`, `rbinom`
- Dist. Poisson: `dpois`, `ppois`, `qpois`, `rpois`
- ...

```
1 ?Distributions
```

Binomial

The Binomial Distribution

Description

Density, distribution function, quantile function and random generation for the binomial distribution with parameters `size` and `prob`.

This is conventionally interpreted as the number of 'successes' in `size` trials.

Usage

```
dbinom(x, size, prob, log = FALSE)
pbinom(q, size, prob, lower.tail = TRUE, log.p = FALSE)
qbinom(p, size, prob, lower.tail = TRUE, log.p = FALSE)
rbinom(n, size, prob)
```

Arguments

<code>x, q</code>	vector of quantiles, the number of successes.
<code>p</code>	vector of probabilities.
<code>n</code>	number of observations. If <code>length(n) > 1</code> , the length is taken to be the number required.
<code>size</code>	number of trials (zero or more).
<code>prob</code>	probability of success on each trial.
<code>log, log.p</code>	logical; if TRUE, probabilities <code>p</code> are given as $\log(p)$.
<code>lower.tail</code>	logical; if TRUE (default), probabilities are $P[X \leq x]$, otherwise, $P[X > x]$.

Por ejemplo, veamos la binomial

- `dbinom(x = 20, size = 50, prob = 0.5) ~ Pr(X = 20) = 0,04185915`

Por ejemplo, veamos la binomial

- `dbinom(x = 20, size = 50, prob = 0.5) ~ Pr(X = 20) = 0,04185915`
- `pbinom(q = 20, size = 50, prob = 0.5) ~ Pr(X ≤ 20) = 0,1013194`
- `pbinom(q = 19, size = 50, prob = 0.5, lower.tail = FALSE)`
`~ Pr(X > 19) = 0,9405398`

Por ejemplo, veamos la binomial

- `dbinom(x = 20, size = 50, prob = 0.5) ~ Pr(X = 20) = 0,04185915`
- `pbinom(q = 20, size = 50, prob = 0.5) ~ Pr(X ≤ 20) = 0,1013194`
- `pbinom(q = 19, size = 50, prob = 0.5, lower.tail = FALSE) ~ Pr(X > 19) = 0,9405398`
- `rbinom(10, 4, 0.5) ~ [3, 3, 3, 3, 2, 1, 0, 2, 3, 2]`
- Hace 10 repeticiones de cuatro experimentos con probabilidad 0.5 y cuenta el número de éxitos.
- `rbinom(5, 1, 0.8) ~ [1, 0, 1, 1, 0]`

Simulación en R

En el caso de la enfermedad que se curaba en un 5 % de los casos, podíamos simplemente hacer:

```
1 pruebas <- rbinom(10000, 9, 0.05)
2 sum (pruebas >= 3)
3 [1] 88
```


Otro caso: El misterio de la boca sana

- Sabemos que en 1970, el 20 % de los escolares tenía la boca libre de caries.
- Tras una campaña educativa, esperamos que % de niños con la boca sana (BS) haya aumentado.
- En un estudio se explora a 5 niños y se encuentra que los 5 tienen la boca sana.
- La hipótesis nula es que la campaña ha sido inútil, pero los hechos observados son que se alcanzado un 100 % de boca sana en la muestra.

Ejercicio: Hallar el p-valor de este experimento

- Vamos a crear 1 millón de muestras de 5 elementos.
- Cada elemento tiene una probabilidad de 0,2
- Por tanto, una binomial de 5 intentos con probabilidad 0,2. Podemos simularla. Y estimar la probabilidad.
- O directamente calcular la probabilidad, $Pr(X = 5)$ y ese sería el p-valor. ¿Con este p-valor, deberíamos aceptar o rechazar la hipótesis nula?

¿Por qué se usa la probabilidad de cola?



¿Probabilidad de cola?

~~$$Pr(3 \text{ curaciones en } 9 \text{ enfermos} | H_0)$$~~

$$Pr(3 \text{ o más curaciones en } 9 \text{ enfermos} | H_0)$$

50 muestras de 10 pacientes

Se sabe que cierta enfermedad se cura espontáneamente en el **5%** de los casos. Para averiguar si la medicina M aumenta las curaciones, se realizan 50 pruebas con muestras de 10 enfermos.

50 muestras de 10 pacientes


Se sabe que cierta enfermedad se cura espontáneamente en el **5%** de los casos. Para averiguar si la medicina M aumenta las curaciones, se realizan 50 pruebas con muestras de 10 enfermos.

```
1 recovery.prob <- 0.05
2 number.of.patients <- 10
3 number.of.trials <- 50
4 results <- rbinom(number.of.trials, number.of.patients,
5   recovery.prob)
```

50 muestras de 10 pacientes

```
1 hist(results, breaks=0:number.of.patients, freq=FALSE)
```

Histogram of results



¿Qué pasa si aumentamos el tamaño de la muestra?


Vamos a incrementar el número de pacientes a 100:

```
1 recovery.prob <- 0.05
2 number.of.patients <- 100
3 number.of.trials <- 50
4 results <- rbinom(number.of.trials, number.of.patients,
5   recovery.prob)
```


50 muestras de 100 pacientes

```
1 hist(results, breaks=0:number.of.patients, freq=FALSE)
```

Histogram of results



Si tomamos la probabilidad de cola...

```
dbinom(50, number.of.patients, success.prob) = 0.07958924
```

Si tomamos la probabilidad de cola...

`dbinom(50, number.of.patients, success.prob) = 0.07958924` _____

- Para $Pr(X \leq x)$: `pbinom(..., lower.tail = TRUE)`
- Para $Pr(X > x)$: `pbinom(..., lower.tail = FALSE)`

Si tomamos la probabilidad de cola...

`dbinom(50, number.of.patients, success.prob) = 0.07958924` _____

- Para $Pr(X \leq x)$: `pbinom(..., lower.tail = TRUE)`
- Para $Pr(X > x)$: `pbinom(..., lower.tail = FALSE)`


-
- `pbinom(50, number.of.patients, success.prob) = 0.5397946`
 - `pbinom(49, number.of.patients, success.prob, FALSE) = 0.5397946`

En resumen

- Cuando el tamaño de la muestra es grande, la probabilidad de cualquier valor (incluido el valor más probable) es extremadamente pequeña
- El límite son las distribuciones continuas, donde la prob. de cualquier valor es 0


En resumen

- Cuando el tamaño de la muestra es grande, la probabilidad de cualquier valor (incluido el valor más probable) es extremadamente pequeña
- El límite son las distribuciones continuas, donde la prob. de cualquier valor es 0
- La probabilidad de un valor concreto no es muy informativa


$$Pr(3 \text{ curaciones en } 9 \text{ enfermos} | H_0)$$

En resumen


- Cuando el tamaño de la muestra es grande, la probabilidad de cualquier valor (incluido el valor más probable) es extremadamente pequeña
- El límite son las distribuciones continuas, donde la prob. de cualquier valor es 0
- La probabilidad de un valor concreto no es muy informativa


$$Pr(3 \text{ curaciones en } 9 \text{ enfermos} | H_0)$$

- Por ello, la probabilidad de cola se usa para cuantificar la compatibilidad o incompatibilidad de los datos muestrales con H_0

$$Pr(3 \text{ o más curaciones en } 9 \text{ enfermos} | H_0)$$

Teorema central del límite



Dadme un punto de apoyo y
moveré el mundo

Arquímedes

Objetivo

- En la población se cumple $H_0 \Rightarrow$ En cualquier muestra se cumple H_0
- El TCL nos da $\Rightarrow$: nos permite relacionar **CUALQUIER** muestra con su población de origen

¿En un universo hipotético donde se cumple H_0 , qué pinta debería tener cualquier muestra?


Distribución de las medias muestrales de una Normal

- Vamos a generar 1000 muestras aleatorias de una dist. normal con $\mu = 60$ y $\sigma = 4$. Cada muestra tendrá 40 elementos
- De cada muestra calculamos la media $\bar{x}$
- Vamos a calcular la media de las medias $\mu_{\bar{x}}$ y la desviación típica de las medias $\sigma_{\bar{x}}$

```
1 sample.means <- rep(NA, 1000)
2 for (i in 1:1000) {
3   sample <- rnorm(40, mean = 60, sd = 4)
4   sample.means[i] <- mean(sample)
5 }
6
7 mean.of.the.sample.means <- mean(sample.means)
8 sd.of.the.sample.means <- sd(sample.means)
9
10 hist(sample.means)
```

Distribución de las medias muestrales de una Normal

- $\mu_{\bar{x}} = 59,96032 \approx \mu = 60$
- $\sigma_{\bar{x}} = 0,6184486 \neq \sigma = 4$




Distribución de las medias muestrales de una Normal

¿Qué pasa si incrementamos el **tamaño de la muestra**?
(e.g., $40 \Rightarrow 1000$)

```
1 sample.means <- rep(NA, 1000)
2 for (i in 1:1000) {
3   sample <- rnorm(1000, mean = 60, sd = 4)
4   sample.means[i] <- mean(sample)
5 }
6
7 mean.of.the.sample.means <- mean(sample.means)
8 sd.of.the.sample.means <- sd(sample.means)
9
10 hist(sample.means)
```

Distribución de las medias muestrales de una Normal

- $\mu_{\bar{x}} = 59,99921$ se parece aún más a $\mu = 60$
- Sigue ocurriendo $\sigma_{\bar{x}} \neq \sigma$
- $\sigma_{\bar{x}} = 0,1277432$ se reduce




Distribución de las medias muestrales de una Normal

¿Qué pasa si disminuimos σ ?

```
1 sample.means <- rep(NA, 1000)
2 for (i in 1:1000) {
3   sample <- rnorm(1000, mean = 60, sd = 1)
4   sample.means[i] <- mean(sample)
5 }
6
7 mean.of.the.sample.means <- mean(sample.means)
8 sd.of.the.sample.means <- sd(sample.means)
9
10 hist(sample.means)
```

Distribución de las medias muestrales de una Normal

- $\mu_{\bar{x}} = 60,00073$ ya es prácticamente idéntica a $\mu = 60$
- Sigue ocurriendo $\sigma_{\bar{x}} \neq \sigma$
- $\sigma_{\bar{x}} = 0,03156694$ se reduce aún más



Distribución de las medias muestrales de una Normal

Resumiendo:

- Las medias muestrales se distribuyen según una normal
- Siempre ocurre que $\mu_{\bar{x}} \approx \mu$
- $\mu_{\bar{x}}$ aproxima mejor a μ cuando más grande es la muestra y menor es σ
- $\sigma_{\bar{x}}$ es directamente proporcional a σ e inversamente proporcional al tamaño de la muestra n

En concreto, se cumple:

$$\sigma_{\bar{x}} = \frac{\sigma}{\sqrt{n}}$$

Distribución de las medias muestrales de una Uniforme


y lo más curioso: ¡¡¡ esto se cumple para

CUALQUIER DISTRIBUCIÓN siempre que $n \geq 30$!!!!

Por ejemplo, vamos a probar con muestras de 1000 valores de una distrución uniforme con $\min=0$ y $\max=1$.

$$\mu = \frac{(\max + \min)}{2} = \frac{1+0}{2} = 0,5 \text{ y } \sigma = \sqrt{\frac{(\max - \min)^2}{12}} = \sqrt{\frac{1-0}{12}} = 0,2886751$$

```
1 sample <- runif(1000)
2 hist(sample)
```



Distribución de las medias muestrales de una Uniforme


Vamos a ver que pasa con la distribución de las medias muestrales:

```
1 sample.means <- rep(NA, 1000)
2 for (i in 1:1000) {
3   sample <- runif(1000)
4   sample.means[i] <- mean(sample)
5 }
6
7 mean.of.the.sample.means <- mean(sample.means)
8 sd.of.the.sample.means <- sd(sample.means)
9
10 hist(sample.means)
```

Distribución de las medias muestrales de una Uniforme

Tachan!!

- $\mu_{\bar{x}} = 0,4997298 \approx \mu = 0,5$
- $\sigma_{\bar{x}} = 0,009601271 \approx \frac{\sigma}{\sqrt{n}} = \frac{0,2886751}{\sqrt{1000}} = 0,009128708$




Distribución de las medias muestrales de una Exponencial

Vamos a hacer otra prueba generando muestras de tamaño 100 de una dist. exponencial con $\lambda = \frac{1}{60}$

$$\mu = \frac{1}{\lambda} = 60 \text{ y } \sigma = \frac{1}{\lambda} = 60$$

```
1 sample <- rexp(100, 1/60)
2 hist(sample)
```




Distribución de las medias muestrales de una Exponencial

```
1 sample.means <- rep(NA, 1000)
2 for (i in 1:1000) {
3   sample <- rexp(100, 1/60)
4   sample.means[i] <- mean(sample)
5 }
6
7 hist(sample.means)
8 mean.of.the.sample.means <- mean(sample.means)
9 sd.of.the.sample.means <- sd(sample.means)
```

Distribución de las medias muestrales de una Exponencial

Tachan!!

- $\mu_{\bar{x}} = 59,98097 \approx \mu = 60$
- $\sigma_{\bar{x}} = 6,146221 \approx \frac{\sigma}{\sqrt{n}} = \frac{60}{\sqrt{100}} = 6$



Teorema Central del Límite

Siempre que se dé ALGUNA de las siguientes condiciones:

- La población sigue una distribución normal
- La población no sigue una distribución normal, pero $n \geq 30$

Se cumplen TODAS las propiedades siguientes:

- Las medias muestrales se distribuyen según una normal
- $\mu_{\bar{x}} = \mu$
- $\sigma_{\bar{x}} = \frac{\sigma}{\sqrt{n}}$

Ejercicio

Comprobar que el TCL se cumple para distribuciones poblacionales geométricas:

- 1 Generar una muestra de 50 individuos de una distribución geométrica con $P = 0,2$ utilizando la función `rgeom( $n$ ,  $P$ )`. Dibujar el histograma
- 2 Generar 1000 muestras aleatorias como la anterior, almacenando en un vector los valores de las medias muestrales $\bar{x}$
- 3 Comprobar que $\mu_{\bar{x}} = \mu$. En una dist. geométrica: $\mu = \frac{1-P}{P}$
- 4 Comprobar que $\sigma_{\bar{x}} = \frac{\sigma}{\sqrt{n}}$.

En una dist. geométrica: $\sigma = \sqrt{\frac{1-P}{P^2}}$


Particularidades de la dist. normal

En la dist. normal, la probabilidad se concentra muchísimo alrededor de la media:

- El 95 % de los casos están entre $\mu - 1,96\sigma$ y $\mu + 1,96\sigma$
- El 99 % de los casos están entre $\mu - 2,58\sigma$ y $\mu + 2,58\sigma$
- En el CERN, el criterio para detectar nuevas partículas del modelo estándar es 5σ , que corresponde a un CI con 0.9999994 de confianza.

Particularidades de la dist. normal

Vamos a verlo en una normal con $\mu = 0$ y $\sigma = 1$:




```
1 integrate(  
2   function(x) dnorm(x, mean = 0, sd = 1),  
3   0-1.96*1,  
4   0+1.96*1)
```

⇒ 0.9500042 with absolute error $\approx 1e-11$

Particularidades de la dist. normal

y en una normal con $\mu = 50$ y $\sigma = 3$:



```
1 integrate(  
2   function(x) dnorm(x, mean = 50, sd = 3),  
3   50-3*1.96,  
4   50+3*1.96)
```

⇒ 0.9500042 with absolute error $\approx 1e-11$

Particularidades de la dist. normal

el código para pintar las normales...

```
1 plot(function(x) dnorm(x, mean = 50, sd = 3),  
2      xlim = c(40, 60))  
3 segments(50-3*1.96, 0, 50+3*1.96, 0.2)  
4 segments(50+3*1.96, 0, 50+3*1.96, 0.2)
```

Intervalo de confianza de $\bar{x}$

- Según el TCL, las medias de las muestras se distribuyen según una normal con $\mu_{\bar{x}} \approx \mu$ y $\sigma_{\bar{x}} = \frac{\sigma}{\sqrt{n}}$
- En toda dist. normal, el 95 % de los casos están (más o menos) a una distancia de 2 desv. típicas de su media

Entonces:

$$\bar{x} \in [\mu - 2\sigma_{\bar{x}}, \mu + 2\sigma_{\bar{x}}]$$

Intervalo de confianza de $\bar{x}$

$$\bar{x} \in [\mu - 2\sigma_{\bar{x}}, \mu + 2\sigma_{\bar{x}}]$$

$$\mu - 2\sigma_{\bar{x}} \leq \bar{x} \leq \mu + 2\sigma_{\bar{x}}$$

$$\mu - 2\sigma_{\bar{x}} \leq \bar{x} \Rightarrow \mu \leq \bar{x} + 2\sigma_{\bar{x}}$$

$$\bar{x} \leq \mu + 2\sigma_{\bar{x}} \Rightarrow \bar{x} - 2\sigma_{\bar{x}} \leq \mu$$

$$\bar{x} - 2\sigma_{\bar{x}} \leq \mu \leq \bar{x} + 2\sigma_{\bar{x}}$$

A partir de una sola muestra, podemos estimar el intervalo donde cae μ más o menos en el 95 % de los casos!:

$$\mu \in [\bar{x} - 2\sigma_{\bar{x}}, \bar{x} + 2\sigma_{\bar{x}}]$$

Intervalo de confianza de $\bar{x}$

- Esa franja que contiene la media poblacional se llama **Intervalo de Confianza (CI)**
- CI al 95 % = $[\bar{x} - 1,96\sigma_{\bar{x}}, \bar{x} + 1,96\sigma_{\bar{x}}]$
- CI al 99 % = $[\bar{x} - 2,58\sigma_{\bar{x}}, \bar{x} + 2,58\sigma_{\bar{x}}]$

A ver si lo entendemos...

```
1  into.the.ci <- 0
2  poblational.mean <- 60
3  poblational.sd <- 4
4  sample.size <- 150
5  for (i in 1:100) {
6    sample <- rnorm(sample.size,
7                    poblational.mean, poblational.sd)
8    sample.mean <- mean(sample)
9    low <- sample.mean - 1.96*(poblational.sd/sqrt(sample.size))
10   high <- sample.mean + 1.96*(poblational.sd/sqrt(sample.size))
11   print(c(low, high))
12   if ( (poblational.mean >= low) && (poblational.mean <= high)) {
13     into.the.ci <- into.the.ci + 1
14   }
15 }
16 print(into.the.ci)
```


Intervalo de confianza de $\bar{x}$

```
1 [1] 59.49401 60.77427
2 [1] 59.72436 61.00463
3 [1] 59.47041 60.75068
4 [1] 59.35423 60.63450
5 [1] 59.44454 60.72480
6 ...
7 > print(into.the.ci)
8 [1] 96
```

- Hemos pasado a considerar que μ como un parámetro
- Para localizarlo, usamos $\bar{x}$
- CI al 95 % quiere decir que la confianza de que μ esté dentro del intervalo es 0.95 (aproximadamente en 95 de cada 100 muestras)
- El CI varía en cada muestra, pues depende de $\bar{x}$ y de $\sigma_{\bar{x}}$ (el CI ganará precisión a medida que aumente n y disminuya σ)

Ya casi lo tenemos...

A partir del **estadístico** de una muestra $\bar{x}$, somos capaces de estimar un **parámetro** de la población μ

El único problema, es que para ello ¡necesitamos conocer el valor de otro parámetro de la población!

$$\sigma_{\bar{x}} = \frac{\sigma}{\sqrt{n}}$$

¿no sería posible estimar σ a partir de la información contenida en cualquier muestra?

Error estándar

La **cuasivarianza muestral** s^2 es un estimador insesgado de la varianza poblacional σ^2

$$s^2 = \frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n - 1} \approx \sigma^2$$

Se puede estimar $\sigma_{\bar{x}}$ con el **error estándar (SE)**

$$\sigma_{\bar{x}} = \frac{\sigma}{\sqrt{n}} \approx \frac{s}{\sqrt{n}} = SE$$


Comprobando que s funciona como estimador de σ

Por ejemplo, vamos a probar con 5000 muestras de 1000 valores de una distrución uniforme con $\min=0$ y $\max=1$.

```
1 sample.s <- rep(NA, 5000)
2 for (i in c(1:5000)) {
3   sample <- runif(1000)
4   s <- sqrt(
5     sum((sample - mean(sample))^2)/(length(sample)-1)
6   )
7   sample.s[i] <- s
8 }
9 mean(sample.s)
10 hist(sample.s)
```

Comprobando que el s sirve para estimar σ

- $\sigma = \sqrt{\frac{(\max - \min)^2}{12}} = \sqrt{\frac{1-0}{12}} = 0,2886751$
- $\bar{s} = 0,2885804$



La distribución normal se nos queda corta...

Estamos superponiendo dos niveles de incertidumbre:

- estimamos μ con $\bar{x}$ y σ
- estimamos σ con la cuasivarianza s

La dist. normal ya no es suficiente, necesitamos:

- una nueva distribución que *meta* en la normal la incertidumbre añadida por s
- la precisión de s depende de n : $s = \sqrt{\frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n-1}}$
- cuanto más pequeña sea la muestra, s será mayor, habrá más incertidumbre, y la nueva distribución tendrá las colas más grandes
- cuanto más grande sea la muestra, s será menor, habrá menos incertidumbre, y la nueva distribución se parecerá más a la normal
- En el límite, $n=\infty$, y la distribución t se convertirá en la normal


Distribución t de Student

La **distribución t de Student** refleja la incertidumbre añadida por s mediante el parámetro:


$$\text{grados de libertad} = n - 1$$

```
1 range <- seq(-4, 4, 0.01)
2 for (i in c(2, 5, 15, 20)) {
3   plot(range, dnorm(range), lty = 1, col = gray(0.5),
4         xlab = "", ylab = "", cex.axis = 1.5)
5   lines(range, dt(range, df = i), lty = 2,
6         lwd = 2)
7   mtext(paste("df=", i), cex = 1.2)
8 }
```


Distribución t de Student




Distribución t de Student



Distribución t de Student



Distribución t de Student



Ejercicio

Comprobar que la estimación del CI utilizando el SE de una muestra funciona correctamente:

- ❶ Generar 1000 muestras aleatorias de 50 individuos de una distribución geométrica con $P = 0,2$ (utilice la función $\text{rgeom}(n, P)$).
- ❷ Calcule la media poblacional: $\mu = \frac{1-P}{P}$
- ❸ Para cada muestra, calcule el CI al 95 % utilizando:
 - ❶ la desv. típica poblacional: $\sigma = \sqrt{\frac{1-P}{P^2}}$
 - ❷ el SE de la muestra (en R, la cuasivarianza se calcula con la función $\text{sd}(\text{muestra})$)
- ❹ Contabilice, mediante 2 contadores, la cantidad de veces que μ cae dentro del CI estimado con σ y con el SE
- ❺ A la vista de los resultados:
 - ❶ ¿Son iguales los 2 contadores?
 - ❷ ¿Son iguales los CI's con σ y con SE? Si no es así, ¿en qué difieren?

Ejercicio

```
1 [1] "_____"  
2 [1] "CI usando desv. tipica poblacional"  
3 [1] 2.820387 5.299613  
4 [1] "CI usando el SE"  
5 [1] 2.95919 5.16081  
6 [1] "_____"  
7 [1] "CI usando desv. tipica poblacional"  
8 [1] 3.060387 5.539613  
9 [1] "CI usando el SE"  
10 [1] 3.04 5.56  
11 ...  
12 [1] "Aciertos del CI usando desv. tipica poblacional"  
13 [1] 94  
14 [1] "Aciertos del CI usando SE"  
15 [1] 94
```

```
print(c(into.the.ci.poblational, into.the.ci.sample))
```

Que no cunda el pánico!



La función **t.test** hace todos los cálculos...

Introducción a la inferencia estadística
Simulación en R
Probabilidad de cola
Teorema central del límite
¿Para que sirve el teorema central del límite?
Distribución t de Student

Error estándar
Distribución t de Student

Ya estamos listos para hacer inferencia...

