



(5) Tests paramétricos mas comunes: t-test y ANOVA. Tipos de errores, potencia y tamaño muestral

Ernesto Aranda Escolástico
Universidad Nacional de Educación a Distancia

**Plasencia 2025 – Curso de Análisis y Visualización de Datos: Estadística
Práctica con R e Inteligencia Artificial**

¿Qué son los tests paramétricos?

Los test o contrastes paramétricos son aquellos test que se utilizan cuando

- Se conoce la distribución de los parámetros de la población (o se asume que siguen una distribución específica).
- Se cumplen las hipótesis subyacentes del contraste paramétrico (normalidad de los datos, homogeneidad de las varianzas, etc.)

Se basan en el cálculo de parámetros estadísticos como la media, la desviación estándar o la varianza.

¿Qué contrastes vamos a estudiar?

- ① **T-test:** Diferencias entre dos grupos.
- ② **ANOVA:** Diferencias entre más de dos grupos.

Potencia estadística

¿Qué librería de R necesito?

```
1 install.packages("effectsize")
2 install.packages("car")
3 install.packages("pwr")
4 install.packages("multcomp")
5 install.packages("psych")
6 install.packages("phia")
7 install.packages("countrycode")
8
9 library(effectsize)
10 library(car)
11 library(pwr)
12 library(multcomp)
13 library(psych)
14 library(phia)
15 library(countrycode)
```

Valores estandarizados

- En la Dist. normal el 95 % de la probabilidad cae en el intervalo $[\mu - 2\sigma, \mu + 2\sigma]$
- Para facilitar la interpretación de los resultados vamos a *estandarizar* los valores: nos preguntaremos ¿cuántas $\sigma_{\bar{x}}$'s se aleja $\bar{x}$ de μ ?

$$\bar{x} - \mu = z\sigma_{\bar{x}} \Rightarrow z = \frac{\bar{x} - \mu}{\sigma_{\bar{x}}}$$

- Recordemos que $\sigma_{\bar{x}} \approx \text{SE}$

Valores estandarizados

- En la Dist. normal el 95 % de la probabilidad cae en el intervalo $[\mu - 2\sigma, \mu + 2\sigma]$
- Para facilitar la interpretación de los resultados vamos a *estandarizar* los valores: nos preguntaremos ¿cuantas $\sigma_{\bar{x}}$'s se aleja $\bar{x}$ de μ ?

$$\bar{x} - \mu = z\sigma_{\bar{x}} \Rightarrow z = \frac{\bar{x} - \mu}{\sigma_{\bar{x}}}$$

- Recordemos que $\sigma_{\bar{x}} \approx \text{SE}$

$$t = \frac{\text{valor muestral} - \text{valor esperado con } H_0}{\text{SE}}$$

Comparación de 2 medias con datos apareados

- *Dependent t-test* o *Paired t-test*
- Se trata de estudiar una variable en un **mismo grupo de individuos** en **2 situaciones** diferentes, por ejemplo, antes y después de hacer ejercicio, o de seguir un determinado tratamiento. Se pretende saber si el ejercicio o el tratamiento modifican la media.

Estadístico

- $t = \frac{\text{valor muestral} - \text{valor esperado con } H_0}{SE}$

Estadístico

- $t = \frac{\text{valor muestral} - \text{valor esperado con } H_0}{SE}$

- $t = \frac{\text{media de las diferencias muestrales} - \text{media de las diferencias con } H_0}{SE}$

$$t = \frac{\text{media de las diferencias muestrales}}{SE}, df = n - 1$$

Ejemplo

10 hombres se someten a una dieta de adelgazamiento:

```
1 weight.pre <- c(81, 74, 75, 71, 80, 76, 72,  
2               75, 80, 75)  
3 weight.post <- c(71, 75, 68, 72, 81, 72, 70,  
4               73, 77, 75)  
5  
6 differences <- weight.post-weight.pre
```

⇒ [-10, 1, -7, 1, 1, -4, -2, -2, -3, 0]

Haciendo los cálculos paso a paso

```
1 se <- sd(differences)/sqrt(10)
2
3 # p-valor
4 t <- mean(differences)/se
5 p.value <- pt(t, df=9)
6
7 # CI
8 t <- qt(0.95, 9)
9 ci.low <- mean(differences) - t*se
10 ci.high <- mean(differences) + t*se
```

$$p - \text{value} = 0,03036917$$

$$\text{CI} = [-4,638632, -0,3613682]$$

Utilizando la función t.test

```
1 t.test(weight.post, weight.pre, paired=TRUE,  
2       alternative="less")
```

Paired t-test

```
data: weight.post and weight.pre  
t = -2.1429, df = 9, p-value = 0.03037  
alternative hypothesis: true difference in means is  
less than 0  
95 percent confidence interval:  
      -Inf -0.3613682  
sample estimates:  
mean of the differences  
      -2.5
```

El tamaño muestral sesga al $p - valor$

- $t = \frac{\text{valor muestral} - \text{valor esperado con } H_0}{SE}$

El tamaño muestral sesga al p – *valor*

- $t = \frac{\text{valor muestral} - \text{valor esperado con } H_0}{\text{SE}}$
- $\text{SE} = \frac{s}{\sqrt{n}}$

El tamaño muestral sesga al $p - valor$

- $t = \frac{\text{valor muestral} - \text{valor esperado con } H_0}{SE}$
- $SE = \frac{s}{\sqrt{n}}$
- $\nearrow n \Rightarrow \searrow SE \Rightarrow \nearrow t \Rightarrow \searrow p - \text{valor}$

El tamaño muestral sesga al p – valor

- $t = \frac{\text{valor muestral} - \text{valor esperado con } H_0}{\text{SE}}$
- $\text{SE} = \frac{s}{\sqrt{n}}$
- $\nearrow n \Rightarrow \searrow \text{SE} \Rightarrow \nearrow t \Rightarrow \searrow p\text{-valor}$

Vamos a verlo experimentalmente

```
1 x1 <- rnorm(10, 100, 10)
2 x2 <- x1 + rnorm(10, 0.1, 0.5)
3 t.test(x1, x2, paired=TRUE)
```

Paired t-test

data: x1 and x2

t = -0.72003, df = 9, p-value = 0.4898

alternative hypothesis: true mean difference is not equal to 0

95 percent confidence interval:

-0.4101032 0.2120700

sample estimates:

mean difference

-0.09901665

Vamos a verlo experimentalmente

```
1 x3 <- rnorm(1000, 100, 10)
2 x4 <- x3 + rnorm(1000, 0.1, 0.5)
3 t.test(x3, x4, paired=TRUE)
```

Paired t-test

data: x3 and x4

t = -5.9699, df = 999, p-value = 3.295e-09

alternative hypothesis: true mean difference is not equal to 0

95 percent confidence interval:

-0.12509935 -0.06320298

sample estimates:

mean difference

-0.09415116

d de Cohen

- $t = \frac{\text{valor muestral} - \text{valor esperado con } H_0}{\frac{s}{\sqrt{n}}}$

d de Cohen

- $t = \frac{\text{valor muestral} - \text{valor esperado con } H_0}{\frac{s}{\sqrt{n}}}$
- Tamaño del efecto: $d = \frac{\text{valor muestral} - \text{valor esperado con } H_0}{s}$

d de Cohen

- $t = \frac{\text{valor muestral} - \text{valor esperado con } H_0}{\frac{s}{\sqrt{n}}}$
- Tamaño del efecto: $d = \frac{\text{valor muestral} - \text{valor esperado con } H_0}{s}$

```
1 x1 <- rnorm(1000, 100, 10)
2 x2 <- x1 + rnorm(1000, 0.1, 0.5)
3
4 d.cohen <- mean(x1-x2)/sd(x1-x2)
5 # Usando el paquete effectsize
6 cohens_d(x1, x2, paired = T)
```

0.227693

d de Cohen

Según *Cohen, J. (1988). Statistical power analysis for the behavioral sciences (2nd ed.). New Jersey: Lawrence Erlbaum:*

- $d = 0,2 \Rightarrow$ Tamaño del efecto pequeño
- $d = 0,5 \Rightarrow$ Tamaño del efecto medio
- $d = 0,8 \Rightarrow$ Tamaño del efecto grande

Ejercicio 1

El dataset “Life_Expectancy_Data.csv”¹ contiene información sobre la esperanza de vida en todo el mundo entre los años 2000 y 2015. Recoge también otras variables relacionadas como el consumo de alcohol, vacunación, gasto en salud, etc.

- 1 Comparar la esperanza de vida del año 2000 con la del 2015. Realizar el t -test para obtener el p -valor y el intervalo de confianza.
- 2 Medir que efecto tiene el método del profesor usando la d de Cohen.

¹<https://www.kaggle.com/datasets/faial1001/life-expectancy-2000-to-2015-all-nations>


Comparación de 2 medias con datos independientes

Se trata de comparar 2 grupos completamente distintos, pudiendo tener cada grupo un n^o distinto de individuos.

Por ejemplo, hombres vs mujeres, grupo de control vs grupo de tratamiento, etc.

Ejemplo

Se ha llevado a cabo un estudio para determinar si el hábito de fumar durante el embarazo tiene algún efecto en el contenido mineral óseo de su hijo (en gr/cm). Para ello se han tomado dos muestras de 12 y 10 recién nacidos cuyas madres fumaron y no fumaron durante el embarazo, respectivamente.



Estadístico

$$t = \frac{\text{valor muestral} - \text{valor esperado con } H_0}{SE}$$

Estadístico

- $t = \frac{\text{valor muestral} - \text{valor esperado con } H_0}{SE}$

- $t = \frac{\text{diferencia de las medias muestrales} - \text{diferencia de las medias pob. con } H_0}{SE}$

$$t = \frac{\bar{x}_1 - \bar{x}_2}{SE}$$

$$SE = \frac{SE_1 + SE_2}{2}$$

$$df = (n_1 - 1) + (n_2 - 1)$$

d de Cohen

$$d = \frac{\bar{x}_1 - \bar{x}_2}{\frac{s_1 + s_2}{2}}$$

Requisito para t-test con datos independientes

- Para hacer el t-test estamos mezclando las varianzas de los grupos:

$$SE = \frac{SE_1 + SE_2}{2}, d = \frac{\overline{x_1} - \overline{x_2}}{\frac{s_1 + s_2}{2}}$$

- Para que esto tenga sentido, la varianza de los grupos debería de ser aproximadamente la misma

$$s_1 \cong s_2$$

Prueba de Levene (Levene's test)

- La **prueba de Levene** es muy similar al t-test, pero en lugar de comparar medias, compara varianzas
- Si hay significancia estadística ($p \leq 0,05$) $\Rightarrow$ la asunción de varianzas homogéneas se está violando
- Si la prueba falla $\Rightarrow$ Hay que ajustar los grados de libertad y el p -valor mediante el **procedimiento de Welch** (Welch's procedure)

Prueba de Levene (Levene's test)

```
1 grupos <- factor(  
2   c(rep(1, length(madres.fumadoras)),  
3     rep(2, length(madres.no.fumadoras))  
4 )  
5 )  
6 leveneTest(c(madres.fumadoras, madres.no.fumadoras),  
7             grupos)
```

Levene's Test for Homogeneity of Variance

(center = median)

	Df	F	value	Pr(>F)
group 1	1	0.275	0.6058	
	20			

t-test

```
1 t.test(madres.no.fumadoras, madres.fumadoras,  
2       var.equal = TRUE, alternative = "greater")
```

Two Sample t-test

```
data:  madres.no.fumadoras and madres.fumadoras  
t = 0.31129, df = 20, p-value = 0.3794  
alternative hypothesis: true difference in means  
is greater than 0  
95 percent confidence interval:  
 -0.01172958      Inf  
sample estimates:  
 mean of x  mean of y  
0.10100000 0.09841667
```

Si el test de Levene hubiera fallado $\Rightarrow$ `var.equal = FALSE`

Cohen's d

```
1 cohens_d(madres.no.fumadoras, madres.fumadoras,  
2         pooled = T)
```

0.133288

El tamaño del efecto es muy pequeño $d < 0,2$

Ejercicio 2

Recuperamos el dataset "Life_Expectancy_Data.csv". Vamos a comparar ahora la esperanza de vida entre los países desarrollados y los que están en vías de desarrollo en el año 2015.

- 1 Realizar el test de Levene para saber el tipo de t -test que puede realizarse.
- 2 Realizar el t -test para obtener el p -valor y el intervalo de confianza.
- 3 Medir que efecto tiene el método del profesor usando la d de Cohen.


Tipos de Error

	H_0 es cierta	H_0 es falsa
Rechazar H_0	<i>Falsa alarma, Falso positivo</i> Error de tipo I $P(R H_0) = \alpha$ 0.05	$\checkmark$ Potencia $P(R \neg H_0) = 1 - \beta$ 0.8
Aceptar H_0	$\checkmark$ $P(\neg R H_0) = 1 - \alpha$ 0.95	<i>Efecto pasado por alto, Falso neg.</i> Error de tipo II $P(\neg R \neg H_0) = \beta$ 0.2²

Cohen considera que salvaguardarse del Tipo I es 4 veces más importante que salvaguardarse del Tipo II ($4 \cdot 0,05 = 0,2$)

²J. Cohen. *Statistical Power Analysis for the Behavioral Sciences*.
Routledge, 1988

Imaginemos que H_0 es cierta




H_0 es falsa


Imaginemos 2 poblaciones distintas...

- $\mu_1 = 60, \sigma_1 = 1$
- $\mu_2 = 62, \sigma_2 = 1$

$H_0 : \mu_1 - \mu_2 = 0$





H_0 es falsa



¿Cuál es el objetivo de un buen contraste de hipótesis?

- 1 Maximizar la potencia
- 2 Minimizar la probabilidad del error de tipo I
- 3 Minimizar la probabilidad del error de tipo II

Problema: $\searrow$ tipo I $\Rightarrow$ $\nearrow$ tipo II





Métodos alternativos para lograr los objetivos

Incrementar el tamaño de la muestra



Según el teorema central del límite:

- Las medias muestrales se distribuyen según una normal
- $\mu_{\bar{x}} = \mu$
- $\sigma_{\bar{x}} = \frac{\sigma}{\sqrt{n}}$
- $\nearrow n \Rightarrow \searrow \sigma_{\bar{x}}$


Incrementar el tamaño de la muestra



Incrementar el tamaño del efecto (Cohen's d)



Cálculo de la potencia en R



- 1 La potencia, el tamaño del efecto d , el tamaño de la muestra n y el nivel de significación α son interdependientes
- 2 Conociendo 3 parámetros cualquiera de ellos, es posible calcular el restante
- 3 El investigador decide de forma directa n y α
- 4 El investigador puede controlar de manera indirecta la potencia y d

El paquete *pwr*

Para calcular la potencia de un *t*-test, el paquete *pwr* ofrece 2 funciones:

- `pwr.t.test` $\Rightarrow$ grupos de datos (apareados o independientes) con el mismo número de individuos ($n_1 = n_2$)
- `pwr.t2n.test` $\Rightarrow$ grupos de datos independientes con distinto número de individuos ($n_1 \neq n_2$)

Parámetros de `pwr.t.test` y `pwr.t2n.test`

- n : nº de individuos por grupo
- d : Cohen's d
- sig.level: α
- power: potencia
- type: paired (datos apareados), two.sample (datos independientes)
- alternative: two.sided, greater, less

Ejemplo

Se trata de evaluar la influencia que tiene hablar por móvil mientras se conduce en el tiempo de reacción. Supongamos que queremos determinar el tamaño de la muestra necesario para :

- ser capaces de detectar el efecto, siempre que exista, con una probabilidad del 90 % $\Rightarrow$ potencia = 0.9
- se espera un tamaño de efecto $d \geq 0,8$
- tener un 95 % de seguridad de que no vamos a cometer un error de tipo I, declarando que hay un efecto que realmente no existe

```
1 pwr.t.test(d=.8, sig.level=.05, power=.9,  
2           type="two.sample", alternative="two.sided")
```

Resultado

Two-sample t test power calculation

```
n = 33.82554
d = 0.8
sig.level = 0.05
power = 0.9
alternative = two.sided
```

NOTE: n is number in *each* group

Nuestro experimento debería contar con, al menos, 34 individuos en cada grupo (conductores hablando con/sin móvil).

Ejemplo

Imaginemos ahora que:

- deseamos tener un 99 % de seguridad de que no vamos a cometer un error de tipo I, declarando que hay un efecto que realmente no existe
- se espera un tamaño de efecto $d \geq 0,5$
- debido a restricciones económicas, nuestro estudio no puede contar con más de 20 individuos por grupo

¿Que potencia cabe esperar? ¿Cual es la probabilidad de que seamos capaces de detectar el efecto si lo hay?

```
1 pwr.t.test(n=20, d=.5, sig.level=.01,  
2           type="two.sample", alternative="two.sided")
```

Resultado

Two-sample t test power calculation

```
n = 20
d = 0.5
sig.level = 0.01
power = 0.1439551
alternative = two.sided
```

NOTE: n is number in *each* group

En estas condiciones, no vale la pena realizar el experimento. Hay un $100 - 0.14 = 86\%$ de probabilidades de que el experimento fracase y no sea capaz de detectar el efecto.

El paquete pwr sirve para otros tipos de tests

- ① Correlación $\Rightarrow$ `pwr.r.test()`
- ② ANOVA $\Rightarrow$ `pwr.anova.test()`
- ③ Chi-cuadrado $\Rightarrow$ `pwr.chi2.test()`
- ④ ...

t-test vs ANOVA

Y Var. Dependiente	X Var. Independiente	Test
Cuantitativa	Cualitativa, 2 niveles	<i>t</i> -test
	Cualitativa, 3 o más niveles	ANOVA

Comparación de 3 o más grupos con t-test

- Imaginemos que queremos comparar 3 grupos de datos G_1, G_2 y $G_3 \rightsquigarrow H_0 : \mu_1 = \mu_2 = \mu_3$

Comparación de 3 o más grupos con t-test

- Imaginemos que queremos comparar 3 grupos de datos G_1, G_2 y $G_3 \rightsquigarrow H_0 : \mu_1 = \mu_2 = \mu_3$
- Para ver si alguno de ellos produce mejores resultados que los demás, podríamos emplear t-tests y comparar los grupos de dos en dos.

Habría 3 posibilidades:

$$A \rightsquigarrow G_1 \text{ vs } G_2 \Rightarrow H_0^{1,2} : \mu_1 = \mu_2$$

$$B \rightsquigarrow G_1 \text{ vs } G_3 \Rightarrow H_0^{1,3} : \mu_1 = \mu_3$$

$$C \rightsquigarrow G_2 \text{ vs } G_3 \Rightarrow H_0^{2,3} : \mu_2 = \mu_3$$

Para descartar $\mu_1 = \mu_2 = \mu_3$, nos bastaría con demostrar que no se cumple cualquiera de las hipótesis nulas:

$$\neg A \vee \neg B \vee \neg C$$

Comparación de 3 o más grupos con t-test

- Combinando A , B y C , tendríamos 8 resultados posibles:

A	$\neg A$	A	A	$\neg A$	A	$\neg A$	$\neg A$
B	B	$\neg B$	B	$\neg B$	$\neg B$	B	$\neg B$
C	C	C	$\neg C$	C	$\neg C$	$\neg C$	$\neg C$

Comparación de 3 o más grupos con t-test

- Combinando A, B y C , tendríamos 8 resultados posibles:

A	$\neg A$	A	A	$\neg A$	A	$\neg A$	$\neg A$
B	B	$\neg B$	B	$\neg B$	$\neg B$	B	$\neg B$
C	C	C	$\neg C$	C	$\neg C$	$\neg C$	$\neg C$

- Para $\alpha = 0,05$, la probabilidad de $\neg A \vee \neg B \vee \neg C$ es:

$$3 \cdot 0,05 \cdot 0,95^2 + 3 \cdot 0,05^2 \cdot 0,95 + 0,05^3 = 0,142$$

Comparación de 3 o más grupos con t-test

- Combinando A, B y C , tendríamos 8 resultados posibles:

A	$\neg A$	A	A	$\neg A$	A	$\neg A$	$\neg A$
B	B	$\neg B$	B	$\neg B$	$\neg B$	B	$\neg B$
C	C	C	$\neg C$	C	$\neg C$	$\neg C$	$\neg C$

- Para $\alpha = 0,05$, la probabilidad de $\neg A \vee \neg B \vee \neg C$ es:

$$3 \cdot 0,05 \cdot 0,95^2 + 3 \cdot 0,05^2 \cdot 0,95 + 0,05^3 = 0,142$$

- $P(\text{muestra} | H_0) = 0,142 \gg \alpha \Rightarrow$ ¡El error de tipo 1 se dispara!

Tipos de ANOVA

	1 Var. Indep.	Más de 1 Var. Indep
Grupos Independientes	One-Way ANOVA	Factorial ANOVA
Grupos Apareados	Repeated-Measures ANOVA	

Análisis Simple - Grupos Indep. (One-way ANOVA)

	1 Var. Indep.	Más de 1 Var. Indep
Grupos Independientes	One-Way ANOVA	Factorial ANOVA
Grupos Apareados	Repeated-Measures ANOVA	

Enunciado del problema

- $Y \sim X$: Y cuantitativa, X cualitativa con I niveles, siendo $I \geq 3$
- I grupos, cada uno con n_I observaciones (las n_I pueden ser distintas)
- N observaciones en total

G_1	G_2	$\dots$	G_I
$x_{1,1}$	$x_{1,2}$	$\dots$	$x_{1,I}$
$x_{2,1}$	$x_{2,2}$	$\dots$	$x_{2,I}$
$\vdots$	$\vdots$	$\vdots$	$\vdots$
$x_{n_1,1}$	$x_{n_2,2}$	$\dots$	$x_{n_I,I}$
$\bar{x}_1$	$\bar{x}_2$	$\dots$	$\bar{x}_I$

Idea feliz: ¿usar la varianza de las medias!

Podríamos pensar en comparar las medias de los grupos, por ejemplo calculando la varianza de las medias:

si las tres medias fueran iguales, la varianza sería 0

Idea feliz: usar la varianza de las medias!

Podríamos pensar en comparar las medias de los grupos, por ejemplo calculando la varianza de las medias:

si las tres medias fueran iguales, la varianza sería 0

```
1 sample1 <- rnorm(11, mean = 60, sd = 4)
2 sample2 <- rnorm(11, mean = 60, sd = 4)
3 sample3 <- rnorm(11, mean = 60, sd = 4)
4 print(c(mean(sample1), mean(sample2),
5         mean(sample3)))
```

63.38499 59.99957 58.39622

```
1 print(var(c(mean(sample1), mean(sample2),
2             mean(sample3))))
```

6.486595

La varianza es muy “variable”

$$\sigma^2 = \frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n}$$

La varianza suma valores positivos y puede llegar a ser un número mucho mayor que 0.


La varianza es muy “variable”

$$\sigma^2 = \frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n}$$

La varianza suma valores positivos y puede llegar a ser un número mucho mayor que 0.

```
1 variances <- rep(NA, 1000)
2 for (i in 1:1000) {
3   sample1 <- rnorm(11, mean = 60, sd = 4)
4   sample2 <- rnorm(11, mean = 60, sd = 4)
5   sample3 <- rnorm(11, mean = 60, sd = 4)
6   variances[i] <- var(c(mean(sample1), mean(sample2),
7                         mean(sample3)))
8 }
9 plot(density(variances), main = "", xlab = "",
10      ylab = "")
```


La varianza es muy “variable”



Otro inconveniente: varianza sistemática vs no sistemática

G_1	G_2	G_3
4	6	2
4	6	2
4	6	2
$\bar{x}_1 = 4$	$\bar{x}_2 = 6$	$\bar{x}_3 = 2$

Otro inconveniente: varianza sistemática vs no sistemática

G_1	G_2	G_3
4	6	2
4	6	2
4	6	2
$\bar{x}_1 = 4$	$\bar{x}_2 = 6$	$\bar{x}_3 = 2$

G_1	G_2	G_3
9	10	1
1	2	5
2	6	0
$\bar{x}_1 = 4$	$\bar{x}_2 = 6$	$\bar{x}_3 = 2$

En este caso hay mucha dispersión dentro de cada grupo

¿No se deberá la varianza entre las medias a dicha dispersión interna?

F -ratio

- Vamos a utilizar como estadístico el F -ratio:

$$F = \frac{\text{varianza entre grupos}}{\text{varianza dentro de los grupos}}$$

- Si $F = 1 \Rightarrow$ no hay efecto

F-ratio

$$F = \frac{\text{varianza entre grupos}}{\text{varianza dentro de los grupos}} \quad (1)$$

$$= \frac{MS_{\text{entre}}}{MS_{\text{dentro}}} = \frac{\frac{1}{DF_{\text{entre}}} SS_{\text{entre}}}{\frac{1}{DF_{\text{dentro}}} SS_{\text{dentro}}} \quad (2)$$

$$= \frac{\frac{1}{I-1} \sum_{j=1}^I n_j (\bar{x}_j - \bar{x})^2}{\frac{1}{N-I} \sum_{j=1}^I \sum_{i=1}^{n_j} (x_{ij} - \bar{x}_j)^2} \quad (3)$$

Grados de libertad


- $DF_{\text{entre}} = I - 1$
- $DF_{\text{dentro}} ?$

Grados de libertad

- $DF_{\text{entre}} = I - 1$
- $DF_{\text{dentro}} ?$
- $DF_{\text{total}} = N - 1$
- $DF_{\text{total}} = DF_{\text{dentro}} + DF_{\text{entre}} \Rightarrow DF_{\text{dentro}} = DF_{\text{total}} - DF_{\text{entre}}$
- $DF_{\text{dentro}} = N - 1 - (I - 1) = N - I$


F de Snedecor / de Fisher-Snedecor

Dist. F, 10 obs. por grupo



Ejemplo: reducción del colesterol

```
1 library(psych)
2 data(cholesterol)
3 describeBy(cholesterol, cholesterol$trt)
4 boxplot(cholesterol$response ~ cholesterol$trt)
```



Ejemplo: reducción del colesterol

```
1 aov.model <- aov(cholesterol$response ~
2                   cholesterol$trt)
3 summary(aov.model)
```

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
cholesterol\$trt	4	1351.4	337.8	32.43	9.82e-13 ***
Residuals	45	468.8	10.4		

Signif. codes: 0 *** 0.001 ** 0.01 * 0.05 . 0.1 1

¡Hay 32 veces más varianza entre los grupos que dentro de ellos!

Tamaño de la muestra

F-ratio

$$F - \text{ratio} = \frac{MS_{\text{entre}}}{MS_{\text{dentro}}} = \frac{\frac{1}{DF_{\text{entre}}} SS_{\text{entre}}}{\frac{1}{DF_{\text{dentro}}} SS_{\text{dentro}}} = \frac{\frac{1}{I-1} \sum_{j=1}^I n_j (\bar{x}_j - \bar{x})^2}{\frac{1}{N-I} \sum_{j=1}^I \sum_{i=1}^{n_j} (x_{ij} - \bar{x}_j)^2}$$

Influencia de N

$\nearrow N \Rightarrow \searrow MS_{\text{dentro}} \Rightarrow MS_{\text{entre}} \gg MS_{\text{dentro}} \Rightarrow F \gg 1 \Rightarrow \searrow$
 $p - \text{valor}$

Tamaño del efecto: Eta-squared η^2

- $\eta^2 = \frac{SS_{\text{entre}}}{SS_{\text{total}}} = \frac{SS_{\text{entre}}}{SS_{\text{entre}} + SS_{\text{dentro}}}$
- $\eta^2 \in [0, 1]$. De manera orientativa (Miles J. and Shevlin M. 2001. Applying Regression and Correlation: A Guide for Students and Researchers. Sage):
 - $\eta^2 = 0,01 \Rightarrow$ efecto pequeño
 - $\eta^2 = 0,06 \Rightarrow$ efecto medio
 - $\eta^2 = 0,14 \Rightarrow$ efecto grande

Ejemplo: reducción del colesterol

```
1 library(lsr)
2 etaSquared(aov.model, anova=T)
```

	eta.sq	eta.sq.part	SS	df	MS	F	p
cholesterol\$trt	0.7424617	0.7424617	1351.3690	4	337.84225	32.43283	9.818812e-13
Residuals	0.2575383	NA	468.7504	45	10.41668	NA	NA

Tamaño del efecto: f de Cohen

- $f = \sqrt{\frac{\eta^2}{1-\eta^2}}$
- De manera orientativa:
 - $f = 0,10 \Rightarrow$ efecto pequeño
 - $f = 0,25 \Rightarrow$ efecto medio
 - $f = 0,40 \Rightarrow$ efecto grande

Potencia: `pwr.anova.test()`

`pwr.anova.test()` para balanced one-way ANOVA (cuando todos los grupos tienen la misma cantidad de individuos):

- k : número de grupos
- n : n^o de individuos por grupo
- f : Cohen's f
- sig.level: α
- power: potencia

Ejemplo: reducción del colesterol

```
1 library(pwr)
2 eta <- etaSquared(aov.model, anova=T)[1,1]
3 Cohen.f <- sqrt(eta^2/(1-eta^2))
4 pwr.anova.test(k=5, n=10, f=Cohen.f, sig.level=0.05)
```

Balanced one-way analysis of variance power calculation


```
      k = 5
      n = 10
      f = 1.108336
sig.level = 0.05
power = 0.9999983
```

NOTE: n is number in each group

pwr.anova.test se puede usar de otras maneras...

Si el tamaño del efecto se prevee mediano ($f = 0,25$), ¿cuántos individuos necesitamos por grupo para $\alpha = 0,05$ y potencia = 0,9?

```
1 pwr.anova.test(k=5, f=0.25,  
2 sig.level=0.05, power=0.9)
```



Balanced one-way analysis
of variance power calculation

```
k = 5  
n = 50.25495  
f = 0.25  
sig.level = 0.05  
power = 0.9
```

NOTE: n is number in each group

Requisitos

- ❶ Los **grupos** son **independientes**: los valores de un grupo no dependen de los valores de los demás grupos
- ❷ Los valores de **cada grupo** siguen una **distribución normal**
⇔ Los residuos del modelo siguen una dist. normal
- ❸ Las **varianzas** de **cada grupo** son **similares**

Requisitos

- normalidad de los residuos

```
1 aov.model <- aov(cholesterol$response ~ cholesterol$trt)
2 aov.residuals <- residuals(object = aov.model)
3 shapiro.test(aov.residuals)
```

Shapiro-Wilk normality test

data: aov.residuals

W = 0.98864, p-value = 0.9094

- homogeneidad de la varianza

```
1 library(car)
2 leveneTest(cholesterol$response, cholesterol$trt)
```

Levene's Test for Homogeneity of Variance (center = median)

Df F value Pr(>F)

group 4 0.0755 0.9893

45

Si se viola la normalidad de los residuos...

Cuando falla el test de Shapiro-Wilk, tenemos varias opciones:

- Continuar con el ANOVA, gracias al Teorema Central del Límite, si
 - ① Cada **grupo** tiene un número grande de observaciones (al menos $n \geq 15$).
 - ② No hay asimetría o valores extremos graves.
- Transformar las variables utilizando funciones como el logaritmo o la raíz cuadrada.
- Utilizar **tests no paramétricos**.

Si se viola la homogeneidad de las varianzas...

Como hacíamos con los t-test, cuando falla el test de Levene, aplicamos procedimiento de Welch.

Por ejemplo, si hubiera fallado Levene:

```
1 oneway.test(cholesterol$response ~ cholesterol$strtr,  
2             var.equal=FALSE)
```

One-way analysis of means (not assuming equal variances)

data: cholesterol\$response and cholesterol\$strtr

F = 30.709, num df = 4.00, denom df = 22.46, p-value = 8.227e-09

Daos cuenta de que el p-valor subiría: de 9.82e-13 a 8.227e-09.

Post-hoc tests: Tukey's procedure

- ANOVA nos dice “hay alguna diferencia en algún sitio”
- Con los Post-hoc tests, “vamos a ver donde está esa diferencia”
- Para ello examinaremos todas las combinaciones de grupos por pares
- Si usáramos t-test para cada par, estaríamos aumentando el error de tipo 1. Por ello usaremos otros test alternativos:
 - Bonferroni's procedure (muy conservador)
 - Tukeys' method (más liberal)

Tukey's 'Honest Significant Difference' method

```
1 TukeyHSD(aov.model)
```

	diff	lwr	upr	p adj
2times-1time	3.44300	-0.6582817	7.544282	0.1380949
4times-1time	6.59281	2.4915283	10.694092	0.0003542
drugD-1time	9.57920	5.4779183	13.680482	0.0000003
drugE-1time	15.16555	11.0642683	19.266832	0.0000000
4times-2times	3.14981	-0.9514717	7.251092	0.2050382
drugD-2times	6.13620	2.0349183	10.237482	0.0009611
drugE-2times	11.72255	7.6212683	15.823832	0.0000000
drugD-4times	2.98639	-1.1148917	7.087672	0.2512446
drugE-4times	8.57274	4.4714583	12.674022	0.0000037
drugE-drugD	5.58635	1.4850683	9.687632	0.0030633

t-test y Bonferroni

```
1 one.time <- subset(cholesterol, trt=="1time")
2 two.times <- subset(cholesterol, trt=="2times")
3 t.test(one.time$response, two.times$response,
4        var.equal = TRUE)
```

```
data: one.time$response and two.times$response
t = -2.4097, df = 18, p-value = 0.02689
alternative hypothesis: true difference in means
is not equal to 0
95 percent confidence interval:
 -6.4448345 -0.4411655
sample estimates:
mean of x mean of y
 5.78197   9.22493
```


t-test y Bonferroni

```
1 with(cholesterol, pairwise.t.test(response, trt,  
2   paired=F, p.adjust.method="bonferroni"))
```

	1time	2times	4times	drugD
2times	0.21333	-	-	-
4times	0.00038	0.34352	-	-
drugD	3.5e-07	0.00106	0.44316	-
drugE	1.1e-12	2.3e-09	3.8e-06	0.00348

Resumen de los resultados 1time vs 2times

Método	p -valor
t-test	0.02689
Tukey	0.1380949
Bonferroni	0.21333

Ejercicio

Recuperamos el dataset “Life_Expectancy_Data.csv”. En este caso, vamos a comparar la esperanza de vida en los diferentes continentes en el año 2015.

- 1 Comprobar que se cumplen los requisitos para utilizar ANOVA: normalidad de la VD (shapiro.test) y homogeneidad de la varianza (leveneTest).
- 2 Obtener el p-valor del ANOVA.
- 3 Calcular el tamaño del efecto (η^2).
- 4 Determinar exactamente donde está el efecto usando un Post-hoc test (TukeyHSD).

Análisis Simple Grupos Apareados (Repeated-Measures ANOVA)

	1 Var. Indep.	Más de 1 Var. Indep
Grupos Independientes	One-Way ANOVA	Factorial ANOVA
Grupos Apareados	Repeated-Measures ANOVA	

Motivación

- ANOVA análogo al t-test para grupos de datos apareados
- En one-way ANOVA: $F - \text{ratio} = \frac{MS_{\text{entre}}}{MS_{\text{dentro}}}$
- En repeated-measures ANOVA la varianza no sistemática se reduce, por que podemos eliminar la varianza estable de los sujetos
- Sólo nos quedamos con la varianza no sistemática de los sujetos a lo largo de los grupos: $F - \text{ratio} = \frac{MS_{\text{entre}}}{MS_{\text{sujetos} \cdot \text{entre}}}$
- Si la varianza no sistemática disminuye $\Rightarrow F$ aumenta
 $\Rightarrow p\text{-valor disminuye} \Rightarrow P(\text{rechazar } H_0 | \neg H_0)$ aumenta (la potencia)

Cálculo del Repeated-Measures ANOVA

```
1 subjects <- factor(rep(1:10, 5))  
2 cholesterol$subjects <- subjects
```

	trt	response	subjects
1	1time	3.8612	1
2	1time	10.3868	2
...			
10	1time	9.4123	10
...			
11	2times	10.3993	1
12	2times	8.6027	2
...			
20	2times	8.3443	10
...			

Cálculo del Repeated-Measures ANOVA

```
1 aov.model <- aov(cholesterol$response ~ cholesterol$trt +
2                 Error(cholesterol$subjects/cholesterol$trt))
3 summary(aov.model)
```

Error: cholesterol\$subjects

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
Residuals	9	231.3	25.7		

Error: cholesterol\$subjects:cholesterol\$trt

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
cholesterol\$trt	4	1351.4	337.8	51.22	2.26e-14 ***
Residuals	36	237.4	6.6		

Signif. codes: 0 *** 0.001 ** 0.01 * 0.05 . 0.1 1

Tamaño del efecto

...

Error: cholesterol\$subjects:cholesterol\$trt

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
cholesterol\$trt	4	1351.4	337.8	51.22	2.26e-14 ***
Residuals	36	237.4	6.6		

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 '1'

$$\eta^2 = \frac{SS_{\text{entre}}}{SS_{\text{total}}} = \frac{SS_{\text{entre}}}{SS_{\text{entre}} + SS_{\text{sujetos·entre}}}$$

```
1 eta.squared <- 1351.4 / (1351.4+237.4)
```


Post-hoc tests: Holm method

```
1 with(cholesterol, pairwise.t.test(response, trt,
2   paired=T))
```

Pairwise comparisons using paired t tests

data: response and trt

	1time	2times	4times	drugD
2times	0.04677	-	-	-
4times	9.2e-05	0.04677	-	-
drugD	5.7e-05	0.00073	0.04677	-
drugE	2.8e-06	7.4e-05	0.00050	0.02353

P value adjustment method: holm

Resumen de los resultados 1time vs 2times

	One-Way	Repeated-Measures
p -valor	9.82e-13	2.26e-14
η^2	0.7424459	0.8505791
p -valor 1time vs 2times	0.1380949 (Tukey)	0.04677 (Holm)

Análisis Doble/Factorial (Two-way/Factorial ANOVA)


	1 Var. Indep.	Más de 1 Var. Indep
Grupos Independientes	One-Way ANOVA	Factorial ANOVA
Grupos Apareados	Repeated-Measures ANOVA	

Ejemplo

```
1 driving.data <- read.table("factorial_anova_data.txt")
```

	subject	conversation	driving	errors
1	1	None	Easy	20
2	2	None	Easy	19
...				
20	20	None	Easy	14
21	21	None	Difficult	10
22	22	None	Difficult	23
...				
40	40	None	Difficult	12
41	41	Low demand	Easy	21
42	42	Low demand	Easy	23
...				

Diagrama de barras



- ¿importa la dificultad de conducción? parece que sí: las barras rojas son mayores que las azules
- ¿importa la complejidad de la conversación? parece que sí: si hiciéramos una barra media entre las rojas y las azules, dicha barra iría cambiando según los niveles de conversación
- ¿hay interacción entre las 2 variables? parece que la diferencia entre las barras rojas y azules se acentúa a medida que aumenta la complejidad de la conversación

Objetivo del Factorial ANOVA

Deseamos comprobar 3 hipótesis:

- 1 ¿hay más errores cuando aumenta la dificultad de conducción?
 $\Rightarrow F_A$
- 2 ¿hay más errores cuando aumenta la complejidad de la conversación? $\Rightarrow F_B$
- 3 ¿hay más errores cuando aumentan las dos variables simultáneamente? $\Rightarrow F_{A \cdot B}$

Requisitos

Los mismos requisitos que los otros ANOVA:

- independencia de los grupos
- normalidad de los residuos

```
1 fact.aov.model <- aov(errors ~ driving*conversation, driving.data)
2 fact.aov.residuals <- residuals(object = fact.aov.model)
3 shapiro.test(fact.aov.residuals)
```

Shapiro-Wilk normality test

data: fact.aov.residuals

W = 0.99377, p-value = 0.8738

Requisitos

- homogeneidad de la varianza

```
1 leveneTest(driving.data$errors ~  
2             driving.data$driving *  
3             driving.data$conversation)
```

Levene's Test for Homogeneity of Variance (center = median)

	Df	F value	Pr(>F)
group	5	0.5206	0.7602
	114		

Cálculo del Factorial ANOVA

```
1 fact.aov.model <- aov(errors ~ driving*conversation,
2                       driving.data)
3 summary(fact.aov.model)
```

	Df	Sum Sq	Mean Sq	F value	Pr(>F)	
driving	1	5782	5782	94.64	< 2e-16	***
conversation	2	4416	2208	36.14	6.98e-13	***
driving:conversation	2	1639	820	13.41	5.86e-06	***
Residuals	114	6965	61			

Signif. codes: 0 *** 0.001 ** 0.01 * 0.05 . 0.1 1

Simple effect analysis

- Cuando encontramos interacción, si deseamos analizar como es esa interacción $\Rightarrow$ examinaremos los efectos simples de una variable bajo los distintos niveles de la otra.
- Podemos usar cualquiera de las estrategias siguientes:
 - Estudiar el efecto de A a distintos niveles de B
 - Estudiar el efecto de B a distintos niveles de A
- Para hacer los calculos, utilizaremos la funcion `testInteractions` del paquete `phia`³

³ ver Sección 3.3. de <https://cran.r-project.org/web/packages/phia/vignettes/phia.pdf>

Dificultad de conducción sobre distintos niveles de conversación


```
1 # creamos el modelo lineal que subyace al ANOVA
2 lm.model <- lm(errors ~ driving * conversation,
3               data=driving.data)
4 # analizamos los efectos simples
5 testInteractions(lm.model, fixed="conversation",
6                 across="driving")
```

Dificultad de conducción sobre distintos niveles de conversación; Resultado

```

1 F Test:
2 P-value adjustment method: holm
3      Value Df Sum of Sq      F      Pr(>F)
4 High demand 20.85   1    4347.2  71.1488 3.519e-13 ***
5 Low demand  17.15   1    2941.2  48.1375 5.117e-10 ***
6      None    3.65   1     133.2   2.1804  0.1425
7 Residuals      114    6965.4
8
9 Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 1

```



La dificultad de conducción sólo afecta a niveles Low y High de conversación

Ejercicio

Recuperamos el dataset “Life_Expectancy_Data.csv”. Ahora vamos a comparar la esperanza de vida, en el año 2014, teniendo en cuenta el continente en el que se ubican y, a su vez, el consumo de alcohol per cápita (bajo, medio y alto). Se pide:

- 1 Preparar los datos del dataset. Dividir el consumo de alcohol en terciles y asignarlo a cada categoría.
- 2 Comprobar que se cumplen los requisitos para utilizar ANOVA: normalidad de la VD (shapiro.test) y homogeneidad de la varianza (leveneTest).
- 3 Utilizar un ANOVA factorial para determinar si hay interacción entre el continente y el consumo de alcohol.
- 4 Para examinar la interacción, analizar los efectos simples.